数据库系统原理 (CS307) 第14讲:查询优化

Zhong-Qiu Wang

计算机科学与工程系 南方科技大学

公告

- · Trigger 作业,截止日期: 2024 年 12 月 15 日 23:59(北京时间)时间
- ·对于项目 II,如果您选择提交 ·截止时间为 2024

年 12 月22 日 (星期日)北京时间23:30

你的项目答辩必须在与答辩同一周的实验室课程中进行。 超过最后期限

您的分数将乘以 1.1

·截至2024年12月29日(星期日)北京时间晚上23:30

·你的项目答辩必须在与答辩同一周的实验室课程中进行。 超过最后期限

您的分数将乘以 1.0

查询优化

·查询优化的目的

·选择一种有效的方法来检索基于查询的数据,同时花费最少的计算工作量

·然而,在大多数情况下,它只是"花费更少的计算努力",而不是至少

查询优化

- ·用户无需考虑编写查询的最佳方式 ·我们希望 DBMS 构建一个查询评估计划,以最小化查询评估的成本
- ·自动优化可以表现更好(大多数时候)
 - ·利用数据字典·根据物理存储 变化的实时利用率·与人类程序员相比,优化器可以在很短的时间 内评估数百个执行计划
 - ·人类用户不再需要学习高级优化技术, 由优化器进行

·同一个查询可以用不同的计划来表示

·例如,检索来自中国的电影的标题

```
select m.title
from movies m, countries c
where m.country = c.country_code and c.country_name = 'China';
```

·相应的关系代数表达式:

```
(1)标题( S 电影.国家 = 国家.国家代码 / 国家.国家 = "中国"(电影 × 国家))
```

- (2)标题(S countries.country = "中国" (电影 movies.country = countries.country_code国家))
- (3) Õtitle (电影 movies.country = countries.country_code { countries.country = "中国" (国家))

·相应的关系代数表达式:

- (1)标题(S 电影.国家 = 国家.国家代码 / 国家.国家 = "中国"(电影 × 国家))
- (2)标题(S countries.country = "中国" (电影 movies.country = countries.country_code国家))
- (3) Õtitle (电影 movies.country = countries.country_code { countries.country = "中国" (国家))

 - 在(2)中,需要缓存一个较小的中间连接表,从而节省一些空间
 - ·在(3)中,过滤器(c.cofuntry = "China")减少了连接操作中右表的大小,从而节省了大量的配对 匹配和缓存中间连接表的时间

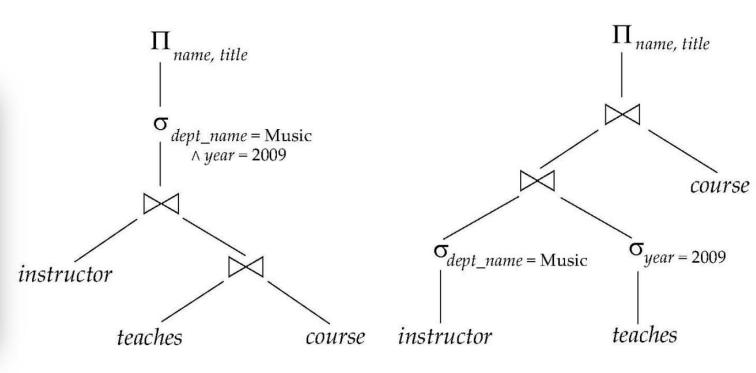
·此外,一旦在国家/地区列上建立索引,过滤操作就可以进一步加速

(3) Õtitle (电影 movies.country = countries.country_code { countries.country = "中国" (国家))

生成等效表达式

·评估给定查询的替代方法·等效表达式·每个操作的不同算法

```
select name, title
from instructor
   natural join (teaches natural join course)
where dept_name = 'Music' and year = 2009;
```



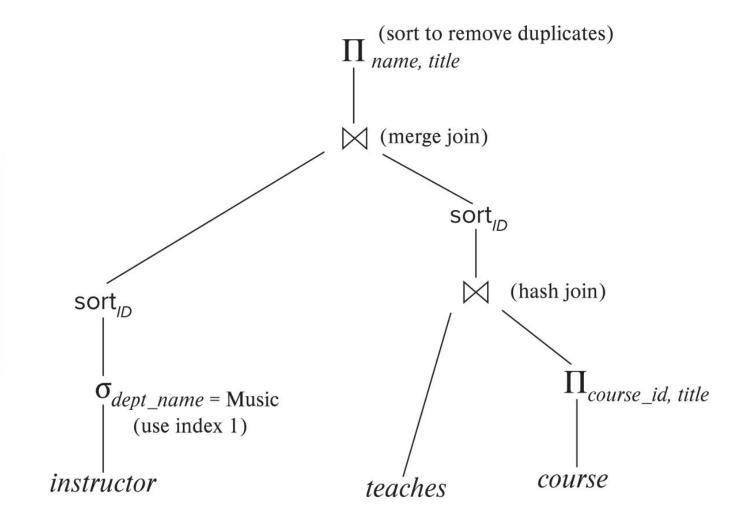
(a) Initial expression tree

(b) Tree after multiple transformations

生成等效表达式

·评估计划明确定义了每个操作使用的算法,以及如何协调操作的执行

```
select name, title
from instructor
   natural join (teaches natural join course)
where dept_name = 'Music' and year = 2009;
```



关系表达式的转换

·如果两个关系代数表达式在每个合法数据库实例上都生成相同的一组元组,则称这两个表达式是等价的______

- ·注意:元组的顺序无关紧要
- ·我们不关心它们是否在违反完整性的数据库上产生不同的结果 约束
- ·等价规则规定两种形式的表达式是等价的
 - ...即,我们可以用第二种形式的表达式替换第一种形式,反之亦然
 - ·优化器使用等价规则将表达式转换为其他逻辑等价表达式

1.连接选择操作可以解构为一系列 個人選擇。

$$\sigma q1 \dot{U} q2 (E) \neq \sigma q1 (\sigma q2 (E))$$

2.选择运算是可交换的

$$\sigma$$
q1 (σ q2 (E)) $\equiv \sigma$ q2 (σ 3。 $-$ 问 (和))

系列投影操作中只需要最后一个,其他操作可以省略

$$\tilde{O}(\tilde{Q}_{1}(\cdots(\tilde{Q}_{L}E))\cdots)) \equiv \tilde{Q}(E)$$

其中L1 \subseteq L2 \cdots \subseteq Ln

4.选择可以与笛卡尔积和θ连接相结合

a) σq (E1 \times E2) \equiv E1 q E2 (与 theta-join 的定义相同)

$$q1 \wedge q2qE2(E1 \quad q2 E2) \equiv E1 \quad b) \sigma$$

5. Theta-join 运算(和自然连接)是可交换的。

E1
$$E2 \equiv E2$$
 E1

6. (a)自然连接运算具有结合性:

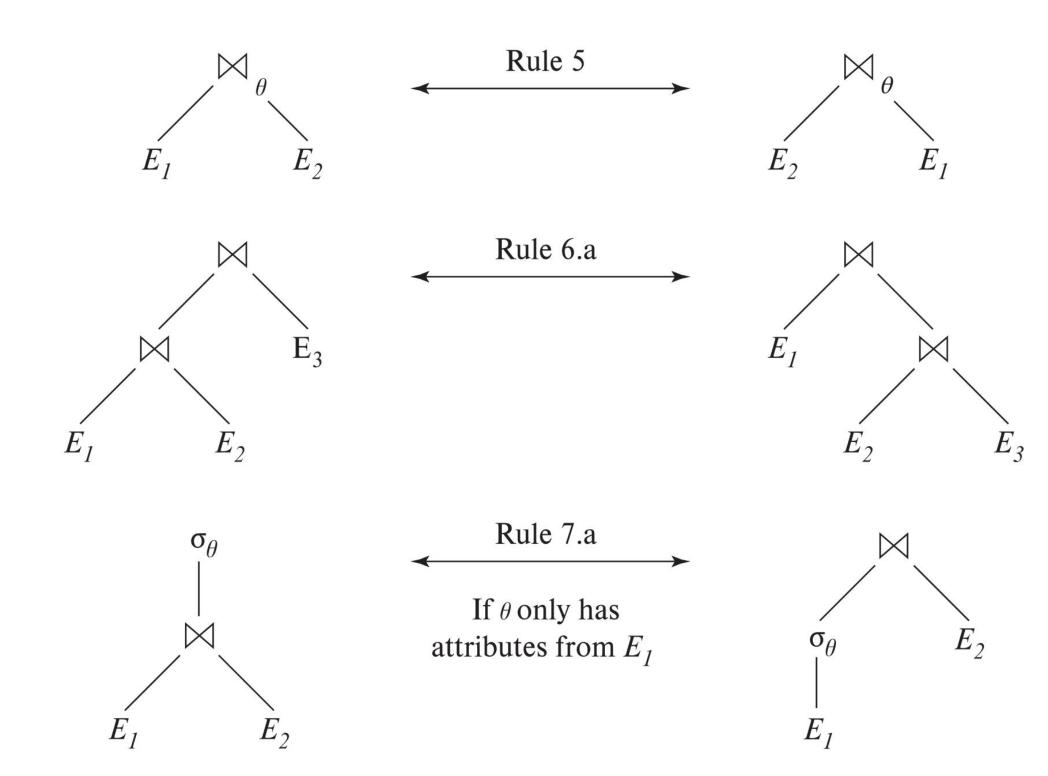
(E1 E2) E3
$$\neq$$
 E1 (E2 E3)

(b) Theta 连接按以下方式关联:

(E1 q1 E2) q2
$$\dot{U}$$
 q3 E3 \neq E1 q1 \dot{U} q3 (E2 q2 E3)

其中q2仅涉及来自E2和E3的属性

·代表 规则 5、6(a) 和 6(b) 附图表



7.在以下两种条件下,选择操作会分布在 theta 连接操作上:

· (a)当q0中的所有属性仅涉及所连接的表达式(E1)之一的属性时: sq0 (E1 q E2) = (sq0 (E1)) q E2

· (b)当q1仅涉及E1的属性且q2仅涉及 E2:

```
sq1\dot{U}q2 (E1 qE2) \equiv (sq1 (E1)) q (sq2 (E2))
```

- 8.投影操作在theta连接操作中的分布如下:
 - (a)如果q仅涉及L1 È L2 中的属性: ·令L1和L2分别为E1和E2的属性集,

他 L1 是 L2(E1 q E2) \equiv \tilde{O} L1 (E1) q \tilde{O} L2(E2)

(b) 一般来说,考虑连接E1 q E2:

令L1和L2分别为E1和E2的属性集,

·假设L3是E1中涉及连接条件q但不在L1中的属性,并且,

·让L4成为E2中涉及连接条件 q 但不在L2中的属性:

他 $_{L1 \neq L2}$ (E1 qE2) \equiv Õ (Õ $_{1 \neq L2}$ $_{L1 \approx L3}$ (E1) qÕ $_{L2 \neq L4}$ (E2))

*

类似的等价关系也适用于左、右和全外连接操作: 、 和

9.集合运算并集和交集是可交换的

E1和E2 ≠ E2和E1

E1 Ç E2 = E2 Ç E1 ·但是,集

合差不交换

10.集合并集和交集是结合的

(E1和E2) AND E3 \neq E1 AND (E2和E3) (E1 Ç E2) Ç E3 \neq E1 Ç (E2 Ç E3)

11.选择操作分布在 È、Ç 和 -

(一个)
$$S = (E1 EE2) = q(E2) S = (E1) E S$$
 (二) $S = (E1 \times E2) \neq q(E2) (E1) 章 S$ (三) $S = (E1 - E2) = q(E2) (E1) - S$ (四) $S = (E1 Ç E2) = q(E1) Ç E2$ (和) $S = (E1 - E2) = q(E1) - E2$

12.投影运算在并集上分配

 $PL(E1和E2) \equiv (PL(E1))和(PL(E2))$

转换示例:推送选择

·查询:查找音乐系所有教师的姓名,以及他们所教课程的名称(在音乐系)

```
select name, title
from instructor natural join (teaches natural join course
where dept_name = 'Music';
```

· Pname, title(sdept_name= 音乐 (讲师 (教学 Pcourse_id, title (课程))))

·使用规则 7(a) 进行变换:

· Pname, title((sdept_name= 音乐 (讲师)) (教学 Pcourse_id, title (课程)))

尽早进行选择可以减少要连接的关系的规模

转换示例:多重转换

·查询:查找 2017 年教授过音乐系课程的所有教师的姓名,以及他们所教授课程的名称

· Pname,title(sdept_name = "音乐"Ùyear = 2017 (讲师 (教授 Pcourse_id ,title (课程))))

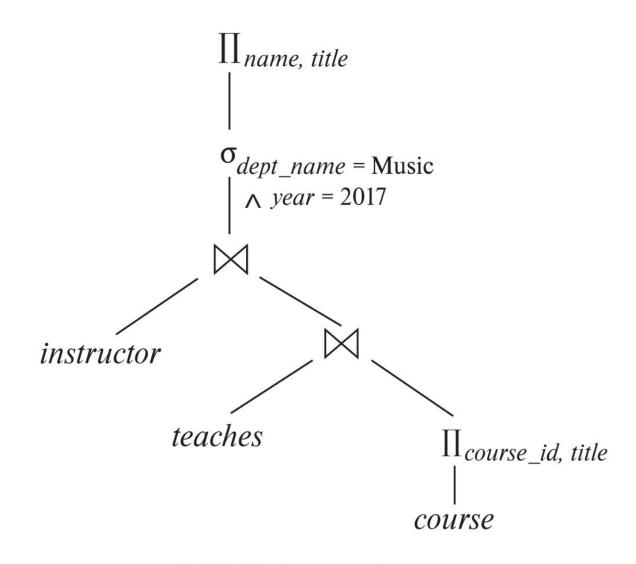
·使用关联连接进行转换(规则 6(a)):

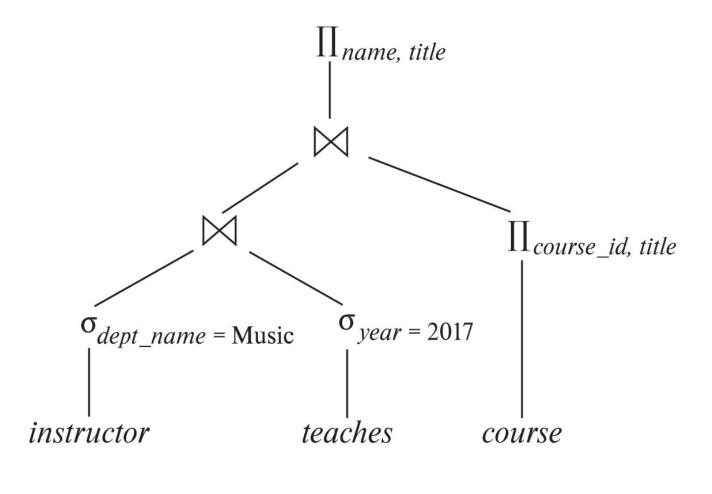
· Pname,title(sdept_name = "音乐"Ùyear = 2017((讲师教授) Pcourse_id ,title(课程)))

·第二形式提供了应用"执行选择"的机会早期"规则,得到子表达式:

· sdept_name = "音乐" (讲师) s year = 2017 (授课)

转换示例:多重转换





(a) Initial expression tree

(b) Tree after multiple transformations

*

转换示例:推动投影

·考虑Pname、title (sdept_name=

音乐"(讲师)教授) Pcourse_id,标题(课程))))

·当我们计算

(sdept_name = "音乐" (讲师) 教学),

我们获得一个关系,其模式为:

(ID、姓名、部门名称、薪水、课程编号、学期编号、年份)

·使用等价规则 8a 和 8b 推动预测;消除不需要的属性 从中间结果得到:

Pname, title (Pname, course_id (sdept_name= 音乐" (讲师) 授课)) Pcourse_id,标题(课程))))

加入订购示例

```
·对于所有关系r1、r2和r3, (r1r2) r3 = r1 (r2 r3)* (连接关联性)
```

·如果r2 r3很大,而r1 r2很小,我们选择(r1 r2) r3,以便计算并存储较小的

临时关系

成本估算

·查询评估计划之间的成本差异可能很大·例如,在某些情况下,几秒与几天

- ·基于成本的查询优化步骤
 - 1. 使用等价规则生成逻辑上等价的表达式 2. 注释结果表达式以获取替代查询计划 3. 根据估计成本选择最便宜的计划

成本估算

·计划成本的估算基于:

有关关系的统计信息,例如: 元组的数量、属性的不同值的数量

中间结果的统计估计

计算复杂表达式的成本

使用统计数据计算的算法成本公式

更多内容请参考参考教材第16.3节"表达结果的统计估计"